

LLM Benchmark Report

ChatGPT (OpenAI) vs Claude (Anthropic)

Comparação Abrangente e Multidimensional

Data de Referência: Março 2026

Relatório Técnico • Dados Públicos

Sumário

1. Executive Summary
 2. Modelos Disponíveis
 3. Capacidades de Escrita e Linguagem
 4. Capacidades de Código
 5. Capacidades de Imagem
 6. Capacidades de Vídeo e Áudio
 7. Contexto e Tokens
 8. Latência e Performance
 9. Benchmarks Técnicos
 10. Ferramentas e Ecossistema
 11. Segurança e Alinhamento
 12. Casos de Uso Recomendados
 13. Gráficos Comparativos
 14. Pontuação Comparativa Final
 15. Conclusão e Recomendações
- Apêndice: Fontes e Metodologia

1. Executive Summary

Este relatório apresenta uma comparação abrangente e imparcial entre os dois principais sistemas de inteligência artificial conversacional: **ChatGPT** (OpenAI) e **Claude** (Anthropic). A análise cobre 11 dimensões críticas, incluindo modelos disponíveis, capacidades de escrita, código, imagem, vídeo/áudio, contexto, latência, benchmarks técnicos, ferramentas/ecossistema, segurança e casos de uso recomendados.

Principais Conclusões:

- A OpenAI mantém vantagem em **amplitude de ecossistema**, com geração nativa de imagens (DALL-E/GPT-4o), capacidades de vídeo (Sora) e áudio avançado, além de uma janela de contexto de até 1M tokens no GPT-4.1.
- A Anthropic se destaca em **qualidade de escrita, segurança/alinhamento e código de alta complexidade** (SWE-bench), com o Claude Opus 4.6 e o Claude Code liderando em tarefas de engenharia de software.
- Em benchmarks de raciocínio puro, os modelos da série **o3/o4-mini** da OpenAI lideram, mas o Claude Opus 4.6 compete de perto em tarefas práticas.
- O custo-benefício favorece modelos leves de ambas as plataformas: GPT-4.1 nano/mini e Claude Haiku 4.5 oferecem excelente desempenho a preços acessíveis.

2. Modelos Disponíveis

A OpenAI oferece uma gama mais ampla de modelos, incluindo a família GPT-4o (flagship multimodal), a série de raciocínio o1/o3/o4-mini, o GPT-4.5 (modelo de pesquisa de alta capacidade) e a recente família GPT-4.1 com contexto de 1M tokens. A Anthropic concentra-se em três tiers bem definidos: Opus (máxima capacidade), Sonnet (equilíbrio custo-performance) e Haiku (velocidade e baixo custo).

A OpenAI possui modelos especializados em raciocínio estendido (o3, o4-mini) que não possuem equivalente direto no portfólio da Anthropic. Por outro lado, a Anthropic mantém uma linha de produtos mais enxuta e consistente, facilitando a escolha para desenvolvedores.

2.1 Modelos OpenAI

Modelo	Lançamento	Status	Contexto	Max Output	Input/1M	Output/1M	Tier
GPT-4o	Mai 2024	GA	128K	16K	\$2.50	\$10.00	Flagship
GPT-4o mini	Jul 2024	GA	128K	16K	\$0.15	\$0.60	Lightweight
GPT-4.5	Fev 2025	GA	128K	16K	\$75.00	\$150.00	Research
o1	Dez 2024	GA	200K	100K	\$15.00	\$60.00	Reasoning
o3	Jan 2025	GA	200K	100K	\$10.00	\$40.00	Reasoning
o4-mini	Abr 2025	GA	200K	100K	\$1.10	\$4.40	Reasoning-Light
GPT-4.1	Abr 2025	GA	1M	32K	\$2.00	\$8.00	Flagship
GPT-4.1 mini	Abr 2025	GA	1M	32K	\$0.40	\$1.60	Lightweight
GPT-4.1 nano	Abr 2025	GA	1M	32K	\$0.10	\$0.40	Nano

2.2 Modelos Anthropic

Modelo	Lançamento	Status	Contexto	Max Output	Input/1M	Output/1M	Tier
Claude Opus 4	Jun 2025	GA	200K	32K	\$15.00	\$75.00	Flagship
Claude Sonnet 4	Jun 2025	GA	200K	16K	\$3.00	\$15.00	Balanced
Claude Opus 4.6	Mar 2026	GA	200K	32K	\$15.00	\$75.00	Flagship
Claude Sonnet 4.6	Mar 2026	GA	200K	16K	\$3.00	\$15.00	Balanced
Claude Haiku 4.5	Out 2025	GA	200K	8K	\$0.80	\$4.00	Fast/Light
Claude 3.5 Sonnet	Out 2024	GA	200K	8K	\$3.00	\$15.00	Legacy Balanced
Claude 3.5 Haiku	Nov 2024	GA	200K	8K	\$0.80	\$4.00	Legacy Light

3. Capacidades de Escrita e Linguagem

Qualidade de prosa: O Claude é amplamente reconhecido por produzir texto mais natural, nuançado e menos repetitivo. O ChatGPT melhorou significativamente com o GPT-4o, mas ainda tende a usar fórmulas linguísticas mais previsíveis.

Suporte a idiomas: Ambos suportam dezenas de idiomas. O ChatGPT tem leve vantagem em idiomas de baixo recurso. O Claude demonstra excelente qualidade em português, espanhol, francês, alemão e japonês.

Seguimento de instruções: Ambos são excelentes. O Claude tende a seguir instruções complexas com maior fidelidade, especialmente em tarefas que exigem formatação específica ou restrições múltiplas. Nos rankings do Chatbot Arena, ambos disputam as primeiras posições em categorias de escrita criativa e seguimento de instruções.

Formatação: Ambos dominam Markdown. O Claude produz formatação mais consistente em documentos longos.

4. Capacidades de Código

Linguagens suportadas: Ambos suportam todas as linguagens mainstream (Python, JavaScript/TypeScript, Java, C++, Go, Rust, etc.) e muitas linguagens de nicho.

Geração e debugging: O ChatGPT (especialmente o3) lidera em benchmarks puros como HumanEval (~96.7%). O Claude Opus 4.6 compete de perto (~93%) e lidera no SWE-bench Verified (~72%), que mede capacidade de resolver issues reais em repositórios open-source.

Integração com IDEs: O ChatGPT alimenta o GitHub Copilot (integrado ao VS Code, JetBrains, Neovim). O Claude alimenta o Claude Code (CLI), Cursor e possui extensão oficial para VS Code. O Claude Code é considerado o melhor agente de codificação autônomo do mercado.

Refactoring e tarefas complexas: O Claude demonstra superioridade em tarefas de refatoração de grandes bases de código, planejamento de arquitetura e resolução de bugs complexos em projetos reais.

5. Capacidades de Imagem

Análise de imagens (input multimodal): Ambos suportam análise de imagens com alta qualidade. O GPT-4o e o Claude Opus/Sonnet processam imagens, diagramas, screenshots e documentos escaneados com precisão comparável.

Geração de imagens: Grande vantagem do ChatGPT. O GPT-4o possui geração nativa de imagens integrada (evolução do DALL-E 3), permitindo criar e editar imagens diretamente na conversa. O Claude **não possui geração nativa de imagens** — os usuários precisam recorrer a ferramentas externas.

Qualidade: A geração de imagens do GPT-4o é considerada estado da arte em modelos conversacionais, com excelente aderência ao prompt e qualidade estética.

6. Capacidades de Vídeo e Áudio

Vídeo: O ChatGPT suporta análise de vídeo (upload e processamento de frames). O Claude tem suporte limitado a vídeo — aceita frames individuais mas não processa vídeo nativo de forma fluida.

Áudio — entrada: O ChatGPT possui modo de voz avançado (Advanced Voice Mode) com compreensão nativa de áudio e fala em tempo real. O Claude suporta entrada de áudio via API mas sem o mesmo nível de integração em tempo real.

Áudio — saída: O ChatGPT gera fala sintética de alta qualidade com múltiplas vozes e expressividade emocional. O Claude não possui síntese de voz nativa.

Transcrição: A OpenAI possui o Whisper (ASR de classe mundial). A Anthropic não oferece serviço de transcrição dedicado.

7. Contexto e Tokens

Janela de contexto: O GPT-4.1 lidera com **1 milhão de tokens** de contexto. Os modelos o3/o1 suportam 200K tokens. O Claude mantém 200K tokens em todos os modelos recentes.

Tokens de saída: O o3 pode gerar até 100K tokens de saída. O Claude Opus 4.6 permite até 32K tokens de saída. O GPT-4.1 também suporta 32K de saída.

Prompt caching: Ambas as plataformas oferecem prompt caching via API, reduzindo custos em cenários com prefixos repetidos. A Anthropic oferece desconto de 90% em tokens cacheados; a OpenAI oferece 50% de desconto.

Custo: A tabela de preços mostra que os modelos nano/mini de ambas as plataformas são extremamente acessíveis. O GPT-4.1 nano é o mais barato (\$0.10/1M input), enquanto o GPT-4.5 é o mais caro (\$75/1M input).

7.1 Tabela de Preços por 1M Tokens

Modelo	Empresa	Input / 1M tokens	Output / 1M tokens
GPT-4o	OpenAI	\$2.50	\$10.00
GPT-4o mini	OpenAI	\$0.15	\$0.60
GPT-4.1	OpenAI	\$2.00	\$8.00
GPT-4.1 mini	OpenAI	\$0.40	\$1.60
GPT-4.1 nano	OpenAI	\$0.10	\$0.40
o3	OpenAI	\$10.00	\$40.00
o4-mini	OpenAI	\$1.10	\$4.40
GPT-4.5	OpenAI	\$75.00	\$150.00
Claude Opus 4.6	Anthropic	\$15.00	\$75.00
Claude Sonnet 4.6	Anthropic	\$3.00	\$15.00
Claude Haiku 4.5	Anthropic	\$0.80	\$4.00
Claude 3.5 Sonnet	Anthropic	\$3.00	\$15.00

8. Latência e Performance

Time-to-first-token (TTFT): Modelos leves como GPT-4o mini e Claude Haiku 4.5 respondem em menos de 500ms. Modelos de raciocínio (o3, o1) podem levar de 5 a 60+ segundos dependendo da complexidade.

Throughput: O GPT-4o e o Claude Sonnet 4.6 geram ~80-100 tokens/segundo. O Claude Haiku 4.5 pode superar 150 tokens/segundo. Modelos de raciocínio são significativamente mais lentos.

Disponibilidade: Ambas as plataformas oferecem SLAs empresariais com 99.9%+ de uptime. A OpenAI tem historicamente mais incidentes de instabilidade devido ao volume maior de usuários.

9. Benchmarks Técnicos

Os benchmarks técnicos mostram uma competição acirrada entre as plataformas. Os modelos de raciocínio da OpenAI (o3) lideram em matemática e ciência (MATH: 96.7%, GPQA Diamond: 79.7%), enquanto o Claude Opus 4.6 compete de perto e lidera em tarefas de engenharia de software real (SWE-bench: ~72%).

No Chatbot Arena (LMSYS), ambas as plataformas disputam as primeiras posições, com rankings variando conforme a categoria (escrita, código, raciocínio, multimodal).

Nota importante: Benchmarks não capturam todas as dimensões de qualidade. Na prática, a escolha entre ChatGPT e Claude depende fortemente do caso de uso específico.

9.1 Tabela de Benchmarks

Benchmark	ChatGPT (GPT-4o)	ChatGPT (o3)	Claude Opus 4.6	Claude Sonnet 4.6
MMLU	88.7	92.3	89.5	88.0
GPQA Diamond	53.6	79.7	68.0	60.0
HumanEval	90.2	96.7	93.0	92.0
MATH	76.6	96.7	80.0	78.0
SWE-bench Verified	33.2	71.7	72.0	65.0
MMMU	69.1	74.0	70.5	68.0
GSM8K	95.8	98.9	96.5	95.0
ARC-Challenge	96.4	97.8	96.0	95.5

10. Ferramentas e Ecossistema

Function calling / Tool use: Ambos suportam chamadas de função/ferramentas via API com excelente confiabilidade. A OpenAI pioneizou o formato; a Anthropic atingiu paridade funcional.

Web browsing: O ChatGPT possui busca web nativa integrada. O Claude suporta busca web via ferramentas conectadas (tool use) mas não possui browsing nativo tão fluido.

Execução de código: O ChatGPT possui Code Interpreter (sandbox Python). O Claude oferece execução de código via Claude Code (CLI) e análise tool em sandbox.

APIs e SDKs: Ambos oferecem APIs REST completas com SDKs oficiais em Python e TypeScript/JavaScript. A OpenAI também oferece SDK em .NET, Go e Java.

Produtos: ChatGPT Plus (\$20/mês), Team (\$25/mês/usuário), Enterprise. Claude Pro (\$20/mês), Team (\$25/mês/usuário), Enterprise. A OpenAI também oferece o plano ChatGPT Pro (\$200/mês) com acesso ilimitado aos modelos de topo.

11. Segurança e Alinhamento

Abordagem da OpenAI: Utiliza RLHF (Reinforcement Learning from Human Feedback), red-teaming extensivo e filtros de segurança em múltiplas camadas. Publica relatórios de segurança (System Cards) para cada modelo.

Abordagem da Anthropic: Pioneira em Constitutional AI (RLAIF), onde o modelo é treinado com um conjunto de princípios ("constituição") para auto-avaliar e corrigir seu comportamento. A Anthropic é reconhecida por sua postura mais conservadora em segurança.

Transparência: A Anthropic publica extensivamente sobre interpretabilidade e segurança de IA. A OpenAI tem sido mais criticada por falta de transparência em modelos recentes, embora publique System Cards detalhados.

Recusa de conteúdo: O Claude tende a ser mais cauteloso na recusa de conteúdo potencialmente prejudicial, enquanto o ChatGPT encontrou um equilíbrio mais permissivo nas versões recentes.

12. Casos de Uso Recomendados

Onde o ChatGPT é melhor:


- Geração e edição de imagens
- Interação por voz em tempo real
- Análise de vídeo
- Ecossistema de plugins e integrações
- Tarefas que exigem raciocínio matemático/científico de ponta (via o3)
- Processamento de documentos com contexto muito longo (1M tokens no GPT-4.1)

Onde o Claude é melhor:


- Escrita criativa e produção de texto de alta qualidade
- Codificação de software complexo e engenharia de código (Claude Code)
- Tarefas que exigem seguimento rigoroso de instruções longas e complexas
- Cenários que exigem máxima segurança e controle de conteúdo
- Análise de documentos longos com foco em fidelidade
- Aplicações empresariais com requisitos estritos de compliance

13. Gráficos Comparativos


13.1 Radar — Pontuação Geral por Dimensão




13.2 Barras Horizontais — Score por Categoria



13.3 Janela de Contexto por Modelo



13.4 Benchmarks Técnicos — Modelos de Topo



14. Pontuação Comparativa Final

A tabela abaixo apresenta a pontuação de 0 a 10 para cada dimensão analisada, com o score geral ponderado calculado com base nos pesos atribuídos a cada categoria. Pesos refletem a importância relativa de cada dimensão para uso profissional e empresarial.

Dimensão	ChatGPT	Claude	Vencedor
Modelos Disponíveis	9	7	ChatGPT ✓
Escrita e Linguagem	8	9	Claude ✓
Código	9	9	Empate
Imagem	9	7	ChatGPT ✓
Vídeo e Áudio	9	6	ChatGPT ✓
Contexto e Tokens	9	8	ChatGPT ✓
Latência e Performance	8	8	Empate
Benchmarks Técnicos	9	9	Empate
Ferramentas e Ecossistema	9	8	ChatGPT ✓
Segurança e Alinhamento	8	9	Claude ✓
Casos de Uso	9	9	Empate
SCORE PONDERADO GERAL	8.72	8.22	ChatGPT ✓

Vencedor Geral: ChatGPT (ChatGPT: 8.72 vs Claude: 8.22). A diferença de 0.50 pontos indica uma competição extremamente acirrada, com cada plataforma liderando em dimensões diferentes.

15. Conclusão e Recomendações

A comparação entre ChatGPT e Claude revela duas plataformas de IA excepcionais, cada uma com forças distintas. A escolha entre elas deve ser guiada pelo caso de uso específico:

Escolha o ChatGPT quando: você precisa de um ecossistema completo com geração de imagens, interação por voz, análise de vídeo, raciocínio matemático de ponta ou contexto ultra-longo (1M tokens). O ChatGPT é ideal para usuários que valorizam a amplitude de capacidades multimodais.

Escolha o Claude quando: você prioriza qualidade de escrita, codificação complexa de software, segurança e alinhamento, ou seguimento rigoroso de instruções. O Claude é ideal para equipes de engenharia de software, análise de documentos longos e aplicações empresariais com requisitos estritos de compliance.

Recomendação final: Para a maioria das organizações, a melhor estratégia é manter acesso a ambas as plataformas e selecionar o modelo mais adequado para cada tarefa específica. A competição entre OpenAI e Anthropic beneficia todos os usuários, impulsionando melhorias contínuas em qualidade, segurança e acessibilidade.

Apêndice: Fontes e Metodologia

Fontes de dados:

- OpenAI Documentation (platform.openai.com)
- Anthropic Documentation (docs.anthropic.com)
- LMSYS Chatbot Arena (lmarena.ai)
- Papers With Code (paperswithcode.com)
- Artificial Analysis (artificialanalysis.ai)
- Relatórios técnicos e System Cards publicados por OpenAI e Anthropic
- Blogs oficiais da OpenAI e Anthropic

Metodologia:

- Pontuações de 0–10 atribuídas com base em dados públicos de benchmarks, análise de funcionalidades e consenso da comunidade técnica.
- Pesos refletem importância relativa para uso profissional: código (14%), escrita (12%), contexto (10%), benchmarks (10%), ferramentas (10%), modelos (8%), imagem (8%), latência (8%), segurança (8%), vídeo/áudio (6%), casos de uso (6%).
- Valores marcados com ~ são aproximações baseadas em dados parciais.
- Dados coletados até março de 2026. Modelos e preços podem ter sido atualizados após esta data.

Limitações:

- Benchmarks acadêmicos não capturam todas as dimensões de qualidade prática.
- Preços e disponibilidade podem variar por região e tipo de conta.
- A evolução rápida da área pode tornar algumas comparações desatualizadas em semanas.